

KNN加權距離解釋



資料探勘課本中在計算KNN時, 每一樣本只有2個欄位

EXCEL中公式除了原來的的方法: 計算兩樣本的距離外

-

另外新增了一個算法: $\text{EXP}(-H_2 * (C_2 * (C_4 - I_{15})^2 + D_2 * (D_4 - I_{16})^2))$

(\$C_4 - I_{15}\$), 及(\$D_4 - I_{16})^2\$)是兩個樣本

\$C_2\$及\$D_2\$是2個欄位的權重

課本意思是-\$H_2\$, 是取距離的半徑, 有點像原始方法的K值

那 $\text{EXP}(-)$, 應該是將原來的距離變成非線性, 以解決/迎合面對要解決的問題

以上是我的理決

-

麻煩正確說明: $\text{EXP}(-H_2 * (C_2 * (C_4 - I_{15})^2 + D_2 * (D_4 - I_{16})^2))$

的由來及WHY 如此作?

非常好的問題, 這一題你理解得已經很接近正確答案了。

下面我幫你**正式、完整**地說明公式

$$\text{EXP}(-H_2 \times (C_2 \times (C_4 - I_{15})^2 + D_2 \times (D_4 - I_{16})^2))$$

的由來、意義與用途。

一、原始 KNN 的距離概念

在傳統的 **KNN (K-Nearest Neighbors)** 演算法中, 我們使用「距離」來衡量樣本間的相似程度。

最常見的是歐式距離 (Euclidean distance) :

$$d(x_i, x_j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2}$$

但在很多應用中, 為了避免平方根、方便計算, 常用平方距離 :

$$d^2(x_i, x_j) = (x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2$$

二、公式中權重的角色

你的公式裡有 C_2 和 D_2 :

$$C_2(C_4 - I_{15})^2 + D_2(D_4 - I_{16})^2$$

這是**加權距離 (weighted distance)**, 代表 :

- 不同的特徵欄位 (例如 C 與 D) 對距離的重要性不同。

- 權重 C_2, D_2 會放大或縮小各維度對距離的影響。

這一步是屬於「**特徵加權 (feature weighting)**」的概念。

三、為何加上 $\text{EXP}(-...)$ ？

這一步是**把距離轉換成相似度 (similarity)**。

傳統的 KNN 是取距離最小的 k 個樣本來投票，

但有一種改良方法（在許多教科書或實作中出現，如「weighted KNN」或「RBF kernel weighting」）：

👉 使用距離的**反比**來當權重。

一般做法有兩種：

1. 線性權重：

$$w_i = \frac{1}{d(x_i, x_j)}$$

→ 距離越近，權重越大。

2. 高斯權重 (Gaussian weight)：

$$w_i = \exp(-\gamma \times d^2(x_i, x_j))$$

其中 γ 是一個常數（在你的公式中就是 γ ）。

四、解釋 $\text{EXP}(-\gamma \times \text{距離}^2)$ 的由來

這個公式直接源自於**高斯分佈 (Gaussian distribution)** 或**徑向基底函數 (RBF, Radial Basis Function)**：

$$K(x, x_i) = \exp(-\gamma \|x - x_i\|^2)$$

在機器學習中：

- SVM 的 RBF kernel
- RBF Neural Network
- 或 weighted KNN
都會採用這種形式。

五、它的意義（為什麼要這樣做？）

1 由距離轉為相似度：

距離小 → 相似度大 → $\text{EXP}(-\text{小數}) \approx 1$

距離大 → 相似度小 → $\text{EXP}(-\text{大數}) \approx 0$

→ 這樣就能把「距離」變成「相似程度」。

2 非線性化：

傳統距離是線性的；

$\text{EXP}(-x^2)$ 則是非線性的，能讓近的樣本影響力更集中，遠的樣本迅速被削弱。這樣能讓 KNN 的「鄰近性」更符合真實分佈（不會被遠端樣本干擾太多）。

3 H_2 (γ) 的角色：

H_2 控制「影響半徑 (radius of influence)」：

- 若 H_2 很大 $\rightarrow \exp(-H_2 \times \text{距離}^2)$ 衰減得很快 $\rightarrow$ 只重視非常近的樣本。
- 若 H_2 很小 $\rightarrow$ 衰減慢 $\rightarrow$ 範圍更廣。

這跟 K 值（鄰居數量）的概念有點類似：都是調整「多遠的點會被算進來」。

六、回到你的公式的完整解釋

$$\text{EXP}(-H_2 \times (C_2 \times (C_4 - I15)^2 + D_2 \times (D_4 - I16)^2))$$

等價於：

$$\text{Similarity} = e^{-\gamma \cdot d_w^2(x, x_i)}$$

其中：

- $d_w^2(x, x_i)$ ：加權距離平方
- $\gamma = H_2$ ：控制距離衰減速率
- 結果：輸出介於 0~1，越近越接近 1，越遠越接近 0。

七、直觀舉例

兩點距離	$\text{EXP}(-H_2 \times \text{距離}^2)$ ($H_2=1$)	說明
0.0	1.000	完全相同
0.5	0.778	很相似
1.0	0.368	中等相似
2.0	0.018	幾乎沒關係

這說明 $\text{EXP}(-x^2)$ 會讓「近的點」影響力極大，「遠的點」幾乎沒影響。


✓ 總結一句話：

這個公式是將「距離」轉為「相似度」的高斯權重函數（RBF函數），用以讓 KNN 模型在面對不同特徵權重與非線性分佈時，更平滑、更準確地評估樣本的鄰近性。

是否要我幫你畫出這個 $\text{EXP}(-x^2)$ 的曲線，讓你一眼看出它與傳統距離的差別？



請畫出曲線



這張圖顯示了高斯相似度函數 $\text{EXP}(-H_2 \times \text{distance}^2)$ 的變化情形：

- 橫軸是「距離」，越右邊表示樣本越遠。
- 縱軸是「相似度」，越高表示樣本越相近。
- 可以看到：
 - 當 $H_2 = 2$ 時，曲線衰減得非常快（僅非常近的樣本有影響）。
 - 當 $H_2 = 0.5$ 時，曲線較平緩，遠一點的樣本仍有一定影響。

這就是「 $\text{EXP}(-H_2 \times \text{距離}^2)$ 」轉換距離為相似度的效果——
控制樣本間影響範圍，使 KNN 或其他模型能更靈活地處理非線性分佈。



麻煩說明高斯分佈（Gaussian distribution）

當然可以。高斯分佈（**Gaussian Distribution**），又稱為**常態分佈（Normal Distribution）**，是統計學與機器學習中最重要、最常見的一種分佈模型。

我們來一步步講清楚它的**數學式、形狀、參數意義、直覺理解與在AI中的應用**。

一、數學定義

高斯分佈的機率密度函數（PDF）是：

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

其中：

符號	意義
x	變數（例如測量值）


符號	意義
μ	平均值 (mean) — 分佈中心位置
σ	標準差 (standard deviation) — 控制分佈的寬窄
σ^2	變異數 (variance)
$\exp()$	指數函數 e^x

二、曲線形狀

高斯分佈是一條**鐘型曲線 (bell curve)**：

- 以 μ 為中心對稱。
- 最高點在 $x = \mu$ 。
- 越遠離平均值的地方，機率密度下降越快（由 $\exp(-x^2)$ 決定）。

視覺化示意：



- 約有 68% 的資料落在 $[\mu-\sigma, \mu+\sigma]$
- 約有 95% 的資料落在 $[\mu-2\sigma, \mu+2\sigma]$
- 約有 99.7% 的資料落在 $[\mu-3\sigma, \mu+3\sigma]$

三、參數影響

參數	影響
μ (平均值)	控制曲線的中心位置。
σ (標準差)	控制曲線的寬度 (σ 大 $\rightarrow$ 曲線寬且平； σ 小 $\rightarrow$ 曲線窄且尖)。

四、 $\exp(-x^2)$ 為什麼出現？

公式中最關鍵的部分是：

$$\exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

這項 **EXP(-平方)** 代表：
離中心越遠，值下降越快；

距離中心越近，值越大。

👉 這個形狀就是「高斯曲線」的核心。

因此，「 $\text{EXP}(-\text{距離}^2)$ 」被廣泛用來衡量**相似度**或**鄰近性**（如你前面提到的 KNN、RBF kernel 等）。

五、與你前面那個公式的關係

你在前一題提到的：

$$\text{EXP}(-H_2 \times \text{距離}^2)$$

這正是高斯分佈中「 $\text{EXP}(-x^2)$ 」那部分的精神，只是：

- 不再做完整的機率密度（省略了前面的常數部分），
- 用於「衡量距離的相似性」，而不是「描述機率分佈」。

因此可以說：

你的 KNN 改良版公式，是從高斯分佈的核心形狀（ $\text{EXP}(-x^2)$ ）延伸出來的，用來將距離轉換成相似度。

六、在 AI 與資料探勘中的應用

領域	使用方式	說明
機器學習 (SVM)	RBF kernel	衡量樣本間的相似度
神經網路 (RBF Network)	隱藏層激活函數	用高斯函數模擬特徵中心
KNN 改良版	權重計算	將距離轉為權重
機率模型	模擬誤差或噪音	假設誤差符合常態分佈
資料探勘	異常偵測	看資料點是否落在「平均值 $\pm k\sigma$ 」之外


七、直觀理解一句話總結：

高斯分佈代表「大多數的資料集中在平均值附近，越遠離中心的情況越少」。
而 $\text{EXP}(-x^2)$ 的形狀正是這種現象的數學表現。

是否要我幫你畫出「不同 μ 、 σ 的高斯分佈曲線」圖？
（會顯示平均值與標準差變化對形狀的影響）



好



這張圖顯示了不同平均值 (μ) 與標準差 (σ) 的高斯分佈曲線：

- μ 改變 → 曲線左右平移（分佈中心不同）。
- σ 改變 → 曲線寬度不同：
 - σ 小（如 0.5）→ 曲線尖且窄，資料集中。
 - σ 大（如 2）→ 曲線平且寬，資料分散。
- 例外 $\mu=3$ 的那條曲線，整個分佈往右移。

這就是高斯分佈的核心特性——由平均值決定位置，標準差決定形狀。