

Excel KNN預測誤差計算



使用Excel作KNN的預測K取1, 預測值只有2個值, 0為不參加, 1為參加
共有十個樣本參與預測, H1到Q1是正確答案, H2到Q2是模型預測的值
在算誤差均方根時

-

1.正確的方法應該是 $\text{SUM}(\text{SQRT}((H1-H2)^2)+\dots+\text{SQRT}((Q1-Q2)^2))$

之後再再除以樣本個數10對吧?

2. 課本上改成如下: $\text{SQRT}(\text{SUMXMY2}(H1:Q1,H2:Q2))/10$

它像是把十個樣本的預測值看成是一個一維的array, 有10個值 (是十維空間上的一個點)

算出與正確答案(十維空間的一個點)的距離後, 再除以十個樣本數

是嗎?

3. 當然, 應該(1)才是對的, (2)的方法有道理嗎? 說得通嗎?

好 — 先把觀念釐清, 然後給出正確的 Excel 寫法與解釋。

1) 你寫的那個式子是不是正確?

你在 (1) 寫的是:

CSS

```
SUM( SQRT((H1-H2)^2) + ... ) / 10
```

注意 $\text{SQRT}((H1-H2)^2) = |H1-H2|$ (絕對誤差)。把每個樣本的絕對誤差加總再除以樣本數, **這其實是 Mean Absolute Error (MAE)**, 不是 RMSE (均方根誤差)。所以 (1) 不是 RMSE, 而是 MAE (若你真的要 MAE, 建議用 $\text{AVERAGE}(\text{ABS}(\dots))$ 或 $\text{SUMPRODUCT}(\text{ABS}(\dots))/10$ 寫法)。

2) 課本的那個式子在做什麼?

課本的式子:

PHP

```
=SQRT(SUMXMY2(H1:Q1, H2:Q2)) / 10
```

$\text{SUMXMY2}(\text{range1}, \text{range2})$ 回傳的是所有對應差值的「平方和」 $S = \sum (y_i - \hat{y}_i)^2$ 。

所以 $\text{SQRT}(\text{SUMXMY2}(\dots)) = \sqrt{S}$, 也就是 **兩個 10 維向量的歐式距離** (L2 範數)。接著他再除以 10, 結果是「歐式距離除以樣本數」。換句話說, 課本把十個樣本當成一個 10 維的點, 算兩點間的距離, 再把距離平均到每一維 (但並非標準的 RMSE)。

數學關係:

- 標準 RMSE: $\text{RMSE} = \sqrt{\frac{S}{n}} = \frac{\sqrt{S}}{\sqrt{n}}$

- 課本公式： $\frac{\sqrt{S}}{n}$.

因此：

$$\text{課本值} = \frac{\text{RMSE}}{\sqrt{n}}.$$

對 $n=10$ ，課本值 = $\text{RMSE} \div \sqrt{10}$ (約 $\div 3.162$)，差異很大。

所以你的理解（把十個樣本看成一個十維點然後取距離）是對的，但把距離再除以 n 這一步會讓結果和常用的 RMSE 定義不一致，數值會小很多。

3) 哪一個比較「說得通／合理」？

- 若你要報 **RMSE**（均方根誤差），正確做法是先求「平均的平方誤差」再開根號：

```
ini
RMSE = SQRT( SUM((y - yhat)^2) / n )
```

在 Excel 範例 ($n=10$)：

- 陣列公式（舊版 Excel）：`=SQRT(AVERAGE((H1:Q1-H2:Q2)^2))`（輸入後按 Ctrl+Shift+Enter）
- 不需陣列的穩定寫法：`=SQRT(SUMPRODUCT((H1:Q1-H2:Q2)^2)/10)`
- 或用 `SUMXMY2`：`=SQRT(SUMXMY2(H1:Q1,H2:Q2)/10)`
- 若你要報 **MAE**（平均絕對誤差），則：
 - `=SUMPRODUCT(ABS(H1:Q1-H2:Q2))/10`
 - 或（陣列）`=AVERAGE(ABS(H1:Q1-H2:Q2))`
- 課本那個 `=SQRT(SUMXMY2(...))/10` 不是常見的評估指標（也不是 RMSE），除非課本有特別理由要把歐式距離再除以 n （例如想報「每維度的 L2 距離 但用 $/n$ 的正規化」），否則我不建議這樣報表或比較模型。

額外建議（因為你的預測是二值 0/1）

對 0/1 預測，除了 RMSE/MAE 之外，通常更常用且直觀的指標有：

- Accuracy**（準確率）：`=SUMPRODUCT(--(H1:Q1=H2:Q2))/10`
- Confusion matrix**（真陽性、真陰性、偽陽性、偽陰性）
- Precision / Recall / F1**
- Brier score**（就是 MSE 對 0/1 預測， $\text{Brier} = \text{mean}((y - p)^2)$ ；若你的預測是 0/1 而非概率，也可以算）

若你只做 0/1 的硬分類（非概率），accuracy + confusion matrix 通常最清楚；如果有機率預測，Brier（或 RMSE）有意義。

結論（給你直接可貼的 Excel 範例）

- 正確 RMSE ($n=10$)：
`=SQRT(SUMXMY2(H1:Q1,H2:Q2)/10)`

或 $=\text{SQRT}(\text{SUMPRODUCT}((\text{H1:Q1}-\text{H2:Q2})^2)/10)$

- MAE :
 $=\text{SUMPRODUCT}(\text{ABS}(\text{H1:Q1}-\text{H2:Q2}))/10$
- Accuracy :
 $=\text{SUMPRODUCT}(--(\text{H1:Q1}=\text{H2:Q2}))/10$

要不要我幫你把 H1:Q1 與 H2:Q2 的實際數據試算出 RMSE / MAE / accuracy ? 你貼數值就行，我立刻算給你。



在回覆中提到: 注意 $\text{SQRT}((\text{H1}-\text{H2})^2) = |\text{H1}-\text{H2}|$ (絕對誤差)。把每個樣本的絕對誤差加總再除以樣本數，這其實是 Mean Absolute Error (MAE)，不是 RMSE (均方根誤差)。所以 (1) 不是 RMSE，而是 MAE

-

那是因為預測值只是0或1, 所以 $\text{MAE} = \text{RMSE}$, 對吧?

如果預測值是一個3個數字組成的 Tuple

那我就會將我的公式再改成: $\text{average}(\text{SQRT}(\text{sumxmy2}(\text{H1}, \text{H2})^2)+...+\text{SQRT}(\text{sumxmy2}(\text{Q1}, \text{Q2})^2))$
這樣就是 RMSE 了吧?

非常好的問題 🍌

你觀察得非常細！我們來一個一個說清楚：

✓ 一、當預測值只有 0 與 1 (二元分類)

是的，你說的沒錯：

因為每一個樣本的誤差只有兩種可能：

- 預測正確： $(y_i - \hat{y}_i)^2 = 0$
- 預測錯誤： $(y_i - \hat{y}_i)^2 = 1$

所以：

$$\text{MSE} = \frac{\text{錯誤樣本數}}{n}$$

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{\text{錯誤樣本數}}{n}}$$

$$\text{MAE} = \frac{\text{錯誤樣本數}}{n}$$

→ 因此 $\text{RMSE} = \sqrt{(\text{MAE})}$ 。

在錯誤率很小時 (例如 < 0.2)，兩者差距很小。

若全部預測正確，兩者都為 0。

但嚴格說 $\text{RMSE} \neq \text{MAE}$ ，只是當誤差只可能是 0 或 1 時，形狀幾乎一樣， $\text{RMSE} = \sqrt{(\text{MAE})}$ 。

✓ 二、如果每一筆資料的預測值是一個「三維 tuple」

例如：

樣本	真實值 (H1~H3)	預測值 (H2~H4)
1	(1, 0, 2)	(0.8, 0.1, 2.1)
2	(0, 1, 1)	(0.1, 0.9, 0.8)
...	...	...

那你想計算每一筆樣本的「向量距離」差，再取平均（然後開根號）——這樣的想法是對的，但要注意步驟。

你的公式：

$$\text{average}(\text{SQRT}(\text{sumxmy2}(\text{H1}, \text{H2})^2) + \dots + \text{SQRT}(\text{sumxmy2}(\text{Q1}, \text{Q2})^2))$$

這裡你是先對每個樣本算出「三維距離」，再取平均。

那實際上是：

$$\text{Average Euclidean Distance} = \frac{1}{n} \sum_{i=1}^n \sqrt{\sum_j (y_{ij} - \hat{y}_{ij})^2}$$

這個 **不是 RMSE**，而是「每樣本的平均歐式距離」(Average Euclidean Distance)。

標準 RMSE 的定義是：

$$\text{RMSE} = \sqrt{\frac{1}{nm} \sum_{i=1}^n \sum_{j=1}^m (y_{ij} - \hat{y}_{ij})^2}$$

其中：

- n 是樣本數
- m 是 tuple 的維度（這裡是 3）

也就是說要「先平方、加總所有元素、平均（跨所有樣本和維度），再開根號」。

✓ 在 Excel 實作的對應關係：

(A) 你那種「每樣本距離再取平均」的做法：

- 是「Average Euclidean Distance」：

```
excel
```

```
=AVERAGE(SQRT(SUMXMY2(H1:J1, H2:J2)), SQRT(SUMXMY2(H3:J3, H4:J4)), ...)
```

👉 用來表示「每樣本的多維距離」的平均，不錯，但不是 RMSE。

(B) 正統 RMSE 寫法（跨所有維度平均平方誤差再開根號）：

若你把三個維度攤平成一條長向量（例如共 10 筆樣本 $\times$ 3 維 = 30 個值），
可以：

```
excel

=SQRT(SUMXMY2(真實值範圍, 預測值範圍) / (樣本數 * 維度數))
```

這樣才是標準 RMSE。

 小結

指標名稱	計算方式	解釋
MAE	平均絕對誤差	對每一維取
RMSE	$\sqrt{\text{平均平方誤差}}$	對所有維度與樣本平方、平均、開根號
Average Euclidean Distance	平均每樣本的向量距離	對每筆樣本先算距離，再平均，不開平方

要我幫你畫一張圖（或用 Excel 範例）比較這三個差異（MAE vs RMSE vs 平均距離）嗎？
會更直觀地看出你那個公式在數學上位於哪一層次。



我似乎有瞭解你的意思

1. 我不能先算完每個樣本的距離, 再除n
2. 而是必須將10個樣本, 3個tuple, 先攤開成一個array, 30個元素
使用SUMXMY2算出平方和, 再除以 n=30
然後再開根號
3. 那我覺得課本的方法應該改成: $\sqrt{\text{SUMXMY2}(H1:Q1, H2:Q2)/10}$
先除n=10, 再開平方
(如果tuple=3, 就是先除n=30, 再開平方), 對嗎?

完全正確 

你現在的理解 **100% 到位**，而且講得非常精準。

我幫你整理成最清楚的三個重點確認：

 (1) 不能先算每個樣本的距離再平均

對。

因為「每筆樣本的距離」本身已經包含平方再開根的動作，
這樣會**破壞平方平均的結構**，變成平均歐式距離（AED），
而非 RMSE。

RMSE 是「所有誤差平方 → 平均 → 再開根號」，
而不是「先開根號 → 再平均」。

👉 換句話說：

$$\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2} \neq \frac{1}{n} \sum \sqrt{(y_i - \hat{y}_i)^2}$$

✅ (2) 若每筆是三維 tuple，要先攤開成一個總長為 30 的陣列

完全正確。

也就是：

$$\text{RMSE} = \sqrt{\frac{1}{n \times m} \sum_{i=1}^n \sum_{j=1}^m (y_{ij} - \hat{y}_{ij})^2}$$

在 Excel 中等價於：

```
excel
```

```
=SQRT(SUMXMY2(真實值範圍, 預測值範圍)/(樣本數*維度數))
```

✅ (3) 課本的公式確實該改成「先除以 n，再開根號」

非常正確。

你這句：

```
SQRT(SUMXMY2(H1:Q1,H2:Q2)/10)
```

就是標準 RMSE 的寫法。

若每樣本有 3 維 tuple，則是：

```
SQRT(SUMXMY2(真實值範圍, 預測值範圍)/(10*3))
```

這樣才符合數學上 RMSE 的定義。

課本原本那種

```
sql
```

```
=SQRT(SUMXMY2(...)) / 10
```

則等於

$$\frac{\sqrt{\sum (y_i - \hat{y}_i)^2}}{n} = \frac{\text{RMSE}}{\sqrt{n}}$$

會少除一個 $\sqrt{n}$ ，數值偏小。

✅ 總結

狀況	正確 RMSE 寫法	錯誤但常見寫法	差異說明
單維 (1 維)	<code>=SQRT (SUMXMY2 (H1:Q1,H2:Q2)/10)</code>	<code>=SQRT (SUMXMY2 (H1:Q1,H2:Q2))/10</code>	少除一個 $\sqrt{n}$
多維 (3 維 tuple)	<code>=SQRT (SUMXMY2 (真實值範圍,預測值範圍)/(10*3))</code>	<code>=SQRT (SUMXMY2 (...))/10</code>	未考慮維度、除錯誤

💡 小提醒：

- 若你預測是 0/1，RMSE = $\sqrt{\text{錯誤率}}$ 。
- 若是多維實數 tuple，那 RMSE 的定義就如上。

要不要我幫你做個小 Excel 範例（10 筆 × 3 維），列出正確 RMSE、課本版本、平均距離 三者數值對照？你會一眼看出差異。