




PYTHON DATA SCIENCE BIBLE 資料科學自學聖經

碁峯資訊

【投影片使用規範與聲明】本投影片僅供非營利教學用途，教師得搭配用書授課講解使用，可於用書期間內將投影片置放於學校內部網站，但需有帳密權限機制，且僅供修課學生瀏覽使用。敬請老師善盡著作權保護之責，請勿將投影片任意散布與販售，亦不得以任何形式或方法轉載內容使用。

進入資料科學的學習殿堂

[1.1 認識資料科學](#)

[1.2 Google Colab：雲端的開發平台](#)

[1.3 Colab 的筆記功能](#)

1.1 認識資料科學

1.1.1 什麼是資料科學？


簡單來說，資料科學就是「透過科學化的方式，對資料進行分析的一門學問，而資料科學存在的目的，在於解決問題」。這裡的「科學化方式」特別強調「資訊科技」與「統計」等跨學科領域的應用。舉例來說，像是Google 公司透過大數據分析，就能藉由使用者查詢感冒症狀的資料，比美國疾病管理局更早掌握流行性感冒疫情發生的情報。

而資料科學的存在就是要讓人類利用資料去看到趨勢，並創造更多創新產品和服務。更重要的是，資料科學可以藉由程式去訓練出模型，利用大量的資料進行學習，進而得到更好的預測答案，進行更好的判斷與決策。


1.1.2 資料科學流程

資料(Data) 經過處理後稱為 資訊(Information)，從這些資訊中分析出有用的訊息，就稱為 知識(Knowledge)，知識經過不斷的驗證與修正，最後形成 智慧(Wisdom)。

資料科學流程就是由資料形成智慧的過程。



資料科學流程的實作過程為：



資料蒐集

資料的型態大致可以分為結構化資料及非結構化資料。結構化資料可以簡單定義為能夠透過表單系統如Google 試算表、微軟Excel 等呈現出來的資料，也就是資料可以透過行列式表格呈現出來。

所有不是結構化資料的資料都屬於非結構化資料。非結構化資料通常是零亂的、沒有規律性的、持續產生的，因此這類資料具有不可預測性。一般使用者蒐集的「原始資料」多為非結構化資料。

資訊擷取


蒐集的非結構化資料需經過整理、過濾等程序才能成為結構化資料，此結構化資料稱為「資料集」。將原始資料製作為資料集需耗費大量金錢及時間，於是許多網站會將製作及蒐集的資料集提供給需要者使用，例如Kaggle 競賽網站、UCI 機器學習資料網站、政府公開資料平台等。

知識轉換

如果認為各項統計數值艱澀難以理解，繪製各式統計圖形的「資料視覺化」是個不錯的選擇，大多數人對於統計圖形都可以一目瞭然。常用的統計圖形有折線圖、散點圖、箱型圖、直方圖等。

智慧生成

當確認資料完整無誤後，就可用機器學習或深度學習建立模型，再使用模型進行預測，操作過程為：



1.1.3 資料科學應用

- 推薦系統
- 智慧城市
- 環境保護
- 社會福利
- 交通運輸
- 醫療保健
- 教育體系

1.2 Google Colab：雲端的開發平台

1.2.1 Colab 的介紹

Colab 的開發方式

Colab 的開發模式是提供雲端版的Jupyter Notebook 服務，開發者無須設定即可使用，還能免費存取 GPU 等運算資源。Colab 預設安裝了一些做機器學習常用的模組，像是 TensorFlow、scikit-learn、pandas 等，在使用與學習時可直接應用！在Colab 中撰寫的程式是以筆記本的方式產生，預設是儲存在使用者的 Google 雲端硬碟中，執行時由虛擬機器提供強大的運算能力，不會用到本機的資源。

Colab 的使用限制

Colab 的筆記本要連線到虛擬機器才能執行，最長生命週期可達 12 小時。閒置太久之後，筆記本與虛擬機器的連線就會中斷，此時只需再重新連接即可。但重新連接時，Colab 等於是新開一個虛擬機器，因此原先儲存於Colab 虛擬機器的資料將會消失，要記得將重要檔案備份到Google 雲端硬碟，避免訓練許久的成果付諸流水。



1.2.2 Colab 建立筆記本

登入 Colab

在瀏覽器用「Colab」關鍵字搜尋，或開啟「<https://colab.research.google.com>」網頁進入 Colab。在首次開啟時需要輸入 Google 帳號進行登入，完成後畫面會顯示筆記本管理頁面。

新增筆記本

Colab 檔案是以「筆記本」方式儲存。在筆記本管理頁面按右下角 **新增筆記本** 就可新增一個筆記本檔案，筆記本名稱預設為Untitled0.ipynb：



Colab 預設檔案儲存位置

Colab 檔案可存於 Google 雲端硬碟，也可存於 Github。預設是存於登入者 Google 雲端硬碟的 <Colab Notebooks> 資料夾中。



1.2.3 Colab 筆記本基本操作


程式碼儲存格的使用

在 Colab 筆記本中，無論是程式或是筆記都是放置在儲存格之中。預設會顯示程式碼儲存格，按 **+ 程式碼** 即可新增程式碼儲存格，按 **+ 文字** 即可新增文字儲存格。在儲存格的右上方會有儲存格工具列，可以進行儲存格上下位置調整、建立連結、新增留言、內容設定、儲存鏡像與刪除等動作。



側邊欄的使用

在左方側邊欄有四個功能按鈕：目錄、尋找與取代、程式碼片段、檔案，點選即可開啟，再按一次或右上角的圖示即可關閉。



使用 GPU 模式

Colab 最為人稱道的就是提供 GPU 執行模式，可大幅減少機器學習程式運行時間。新增筆記本時，預設並未開啟 GPU 模式，可依以下操作變更為 GPU 模式：執行編輯 / 筆記本設定。



在 硬體加速器 欄位的下拉式選單點選**GPU**，然後按 儲存。

虛擬機器的啟停與重整


開啟Colab 筆記本時，預設沒有連接虛擬機器。按 **連線** 鈕連接虛擬機器。



1.2.4 Colab 虛擬機器的檔案管理


虛擬機器的預設資料夾

當Colab 筆記本成功連接虛擬機器後，在側邊欄的 **檔案** 即可看到機器的預設資料夾，已自動產生了一個<sample_data> 資料夾，其中放置了機器學習與深度學習中常用來練習的幾個資料集。




上傳檔案到虛擬機器

如果要將檔案上傳到虛擬機器中使用，可以按下  **上傳** 按鈕開啟視窗，選取要上傳的檔案。若是一次要上傳多個檔案，可以在選取時按著 **Ctrl** 鍵不放，選取所有要上傳的檔案，最後按下 **開啟** 鈕即可進行上傳。




虛擬機器檔案的管理功能

如果要針對上傳的檔案進行管理，可以按下檔名旁的 開啟選單，接著再選取要執行的動作。



虛擬機器檔案的瀏覽功能

Colab 還提供多種檔案的瀏覽功能：如果是文字內容的檔案，如txt、json 等，在檔名點擊二下即可開啟一旁的瀏覽視窗，甚至可以進行編輯的動作，系統會自動存檔。



1.2.5 Colab 掛接Google 雲端硬碟

自行新增的Colab 筆記本連接Google 雲端硬碟

若Colab 筆記本是由使用者自行新增時，掛接Google 雲端硬碟的步驟就很單純。

1. 請按下側邊欄 檔案 分頁的  掛接雲端硬碟 鈕。



使用上傳的筆記本連接Google 雲端硬碟

如果上傳的筆記本檔案、開啟官方的範例為副本，或是匯入Github 上筆記本的檔案為副本，要連接Google 雲端硬碟就可能要多一些步驟。


1. 按下側邊欄 **檔案** 的  **掛接雲端硬碟** 鈕，此時會自動產生程式儲存格內容如下：

```
from google.colab import drive
drive.mount('/content/drive')
```



Colab 使用Google 雲端硬碟檔案


在Google 雲端硬碟中切換到<Colab Notebooks> 資料夾，按左上方 **新增** 鈕，再點選 **檔案上傳**，於 **開啟** 對話方塊選擇要上傳的檔案就可將該檔案上傳到雲端硬碟的<Colab Notebooks> 資料夾，上傳後可在Google 雲端硬碟看到該檔案。



Google 雲端硬碟檔案的絕對路徑位於：

```
/content/drive/My Drive/Colab Notebooks/ 檔案名稱
```

如果不確定檔案的路徑，可以開啟 Colab 側邊欄的 **檔案** 分頁，掛接Google 雲端硬碟後，再依路徑找到檔案，按右鍵後選 **複製路徑** 即可取得絕對路徑。



1.2.6 執行Shell 命令：「！」

Colab 允許使用者執行Shell 命令與系統互動，只要在「！」後加入命令語法，格式為：

```
!shell 指令
```

其中用於管理Python 模組的命令：「pip」就是一個相當重要的命令。例如要安裝用於下載Youtube 影片的pytube 模組的命令為：

```
!pip install pytube
```

如果想要查看系統中已安裝的模組，可以使用：

```
!pip list
```

除此之外，還可以使用Shell 命令來進行檔案或是系統的操作，例如以「pwd」命令查看現在目錄：

```
!pwd
```

以下是Colab 中常用來操作系統的Shell 命令：

命令	說明
ls [-l]	顯示檔案或目錄內容結構 -l: 詳細檔案系統結構
pwd	顯示當前目錄
cat [-n] 檔名	顯示檔案內容 -n: 顯示行號
mkdir 目錄名稱	建立新目錄
rmdir 目錄名稱	移除目錄，目錄必須是空的
rm [-i] [-rf] 檔案或目錄名稱	移除檔案或目錄。 -i: 刪除前需確認 -rf: 刪除目錄，其中目錄不必是空的。
mv 檔案或目錄名稱 目的目錄	移動檔案或目錄到目的目錄。
cp [-r] 檔案或目錄名稱 目的目錄	複製檔案或目錄到目的目錄。 -r: 複製目錄
ln -s 目錄名稱 虛擬目錄名稱	將目錄名稱設為虛擬名稱，常用於簡化 Google 雲端硬碟目錄。
unzip 壓縮檔名	將壓縮檔解壓縮。
sed -i 's/ 搜尋字串 / 取代字串 /g' 檔案名稱	將檔案中所有「搜尋字串」取代為「取代字串」。
wget [-o 自訂檔名] 遠端檔案網址	下載遠端檔案回到本機。 -o: 可自訂檔名。

1.2.7 魔術指令：「%」

Colab 提供魔術指令(Magic Command) 供使用者擴充Colab 功能，分為兩大類：

1. 行魔術指令(Line Magic) 以「%」開頭，適用於單行命令。
2. 儲存格魔術指令(Cell Magic) 以「%%」開頭，適用於多行命令。

%lsmagic

「%lsmagic」功能是顯示所有可用的魔術指令，可進行指令的查詢。

%cd

「%cd」功能是切換目錄，語法為：

```
%cd 目錄名稱
```

%timeit 及%%timeit

這兩個指令都會計算程式執行的時間：「%timeit」用於單列程式，「%%timeit」用於整個程式儲存格。

%%writefile

「%%writefile」功能是新增內容為文字檔，語法為：

```
%%writefile 檔案名稱  
檔案內容  
.....
```

%run

「%run」功能是執行檔案，語法為：

%run 檔案名稱


%whos

「%whos」功能是查看目前存在的所有變數、類型等。

1.2.8 Colab 筆記本檔案的下載與上傳

下載筆記本檔案

請選取功能表 **檔案 / 下載 / 下載 .ipynb**，即可將檔案下載到本機儲存。



上傳筆記本檔案

請選取功能表 / 檔案 上傳筆記本 開啟對話視窗，點選 上傳 功能，再點選 選擇檔案鈕，於 開啟 對話方塊選取要上傳的<.ipynb> 檔即可。



1.3 Colab 的筆記功能

請在功能表按 **插入 \ 文字儲存格**，或按 **+ 文字** 鈕新增一個文字儲存格。文字儲存格使用markdown 語法建立具有格式的文字(Rich Text)，可在右方看到呈現的文字預覽，系統並提供簡易的markdown 工具列，讓使用者能快速建立格式化文字。



1.3.1 Markdown 語法

Markdown 就顯示的結構上可區分為兩大類：區塊元素 及 行內元素。

- **區塊元素**：此類別會讓內容獨立形成一個區塊，區塊內的全部文字都是套用同樣的格式。
- **行內元素**：套用此類別的內容可插入於區塊內。


1.3.2 區塊元素

區塊元素會讓內容獨立形成一個區塊，區塊內的全部文字都是套用同樣的格式，例如標題、段落、清單等。

標題文字


標題文字分為六個層級，是在標題文字前方加上1到6個「#」符號，「#」數量越少則標題文字越大。

- 注意：「#」與標題文字間需有一個空白字元。




段落文字

當沒有加上任何標示符號時，該區塊的文字就是文字段落區塊，段落與段落之間則是以空白列分開。



引用文字


引用文字是在文字前方加上「>」符號，功能是文字樣式類似於 Email 回覆時原文呈現的樣式。




清單

清單可分為 **項目符號清單** 及 **編號清單**。

1. **項目符號清單** 是在文字前方加上「-」或「+」或「*」符號及一個空白字元，功能是建立清單項目。




2. **編號清單** 是以數字加上「.」及一個空白字元做為開頭的文字，功能是建立包含數字編號的清單項目。



分隔線

分隔線是連續3 個「*」或「_」符號，功能是建立一條橫線以分隔文字。



區塊程式碼


Markdown 說明中常需要顯示程式碼，其語法為：

```
```  
程式碼
.....
```
```

1.3.3 行內元素


斜體文字

若文字被「_」或「*」符號包圍，該文字就會以斜體文字顯示。



粗體文字

若文字被「`_`」或「`**`」符號包圍，該文字就會以粗體文字顯示。




超連結

建立超連結文字有兩種方法：HTML 語法或Markdown 語法。


HTML 語法：

```
<a href="網址">顯示文字</a>
```




Markdown 語法：

```
[顯示文字](網址)
```



行內程式碼

行內程式碼是在一般文字中顯示程式碼，其語法是將程式碼以反引號「`」包圍起來即可。




圖片

建立圖片有兩種方法：HTML 語法或Markdown 語法。

HTML 語法：

```

```



Markdown 語法：

```
![ 替代文字 ]( 圖片網址 )
```

