

四分位法處理異常值



麻煩針對: 數據分析, 在處理異常值時, 常用的 (四分位)法 進明說明

當然可以 🙌 以下是針對「數據分析中，處理異常值（outliers）時常用的四分位法（IQR法）」的清楚說明：

🎯 一、基本概念

在數據分析中，**異常值（Outlier）** 是指明顯偏離其他觀測值的數據點。這些異常值可能是：

- 輸入錯誤（例如打錯資料）
- 特殊事件造成（例如極端天氣）
- 或是確實存在的重要現象

為了避免這些異常值對平均值或模型造成過度影響，常使用「**四分位距法（Interquartile Range, IQR）**」來偵測與處理。

📊 二、四分位法 (IQR法) 的計算步驟

假設資料集為一組數值：

Step 1：將資料 由小到大排列

Step 2：找出四分位數

- **Q1（第一四分位數）**：第 25% 的位置
- **Q2（中位數 Median）**：第 50% 的位置
- **Q3（第三四分位數）**：第 75% 的位置

Step 3：計算四分位距

$$IQR = Q3 - Q1$$

🚨 三、判斷異常值的標準（IQR規則）

通常定義如下：

- **下界（Lower Bound）** = $Q1 - 1.5 \times IQR$
- **上界（Upper Bound）** = $Q3 + 1.5 \times IQR$

若資料點：

- 小於下界 → 被視為「**下方異常值**」
- 大於上界 → 被視為「**上方異常值**」

(若要更嚴格，也有人用 $3 \times \text{IQR}$ 來界定極端異常值。)

四、舉例說明

假設資料如下：

```
csharp
```

```
[2, 4, 5, 7, 8, 9, 10, 15, 18]
```

排序後：

已排序。

- $Q1 = 5$
- $Q2$ (中位數) = 8
- $Q3 = 10$
- $\text{IQR} = 10 - 5 = 5$

下、上界：

- 下界 = $5 - 1.5 \times 5 = -2.5$
- 上界 = $10 + 1.5 \times 5 = 17.5$

因此：

- 小於 -2.5 的沒有
- 大於 17.5 的是 18 → **屬於異常值**

五、實務應用方式

在資料分析或機器學習前常會：

1. **偵測異常值** (畫箱型圖 boxplot 或用程式計算)
2. 視情況決定：
 - 刪除異常值 (若為錯誤資料)
 - 或保留 (若為真實的極端現象)
 - 或以中位數或平均值取代 (視情況而定)

六、Python範例

```
python

import pandas as pd

# 假設有一個欄位 'score'
Q1 = df['score'].quantile(0.25)
Q3 = df['score'].quantile(0.75)
IQR = Q3 - Q1

lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

# 找出異常值
outliers = df[(df['score'] < lower_bound) | (df['score'] > upper_bound)]
```

七、可視化輔助：箱型圖 (Boxplot)

箱型圖會顯示：

- Q1、Q2、Q3（箱體）
- IQR範圍（箱體高度）
- 超出範圍的點（異常值）

例如：

```
python

import seaborn as sns
sns.boxplot(x=df['score'])
```

是否希望我幫你畫一張「四分位法異常值檢測的圖解（含箱型圖與邊界標示）」？
這樣會更直覺地看懂整個流程。



Q1 = 應為 $(4+5)/2$

非常好 🍌 你觀察得很細！

我們就用剛剛那組資料來仔細算一次 Q1、Q2、Q3，看看為什麼會是 $(4 + 5)/2$ 。

✅ 資料集：

```
csharp

[2, 4, 5, 7, 8, 9, 10, 15, 18]
```

共有 9 筆資料。

Step 1：找出 Q2（中位數）

因為有 9 筆（奇數筆），
→ 第 5 個數為中位數。

$$Q2 = 8$$

Step 2：分成「下半部」與「上半部」

- 下半部（中位數左邊）：[2, 4, 5, 7]
- 上半部（中位數右邊）：[9, 10, 15, 18]

Step 3：找出 Q1 與 Q3

各自取中位數（因為這兩邊都是偶數筆資料，所以要取平均）

- $Q1 = (4 + 5)/2 = 4.5$
- $Q3 = (10 + 15)/2 = 12.5$

Step 4：計算 IQR 與邊界

$$IQR = Q3 - Q1 = 12.5 - 4.5 = 8.0$$

$$\text{下界} = Q1 - 1.5 \times IQR = 4.5 - 12 = -7.5$$

$$\text{上界} = Q3 + 1.5 \times IQR = 12.5 + 12 = 24.5$$

Step 5：判斷異常值

在這裡：

- 沒有小於 -7.5 的值
- 沒有大於 24.5 的值

→ 所以這組資料 **沒有異常值**。

💡 補充說明：

你指出 $Q1 = (4 + 5)/2$ 的說法是正確的，
我前一次的例子用的是簡化概念（直接取近似四分位數），
但若**要精確計算**，應該依照上述步驟進行。

是否希望我幫你整理成一個「四分位法完整範例表格」，
包含每個步驟與結果（Q1, Q2, Q3, IQR, 邊界、是否異常）？